

Matematički fakultet

Univerzitet u Beogradu

Prepoznavanje umetničkih pokreta pomoću dubokih CNN mreža

Predmet: Mašinsko učenje

Anja Jovanović, 1044/2025

Mateja Stojanović, 1107/2025

Beograd, avgust 2026.

Sažetak

Rad se bavi klasifikacijom slika umetničkih dela u jedan od 18 umetničkih pokreta na skupu Pandora 18K. Testirali smo četiri modela: dve konvolucione mreže trenirane od nule (VGG-lite i hibrid sa Inception-stil granom) i transfer learning sa InceptionV3, prvo sa novom dense glavom, a zatim sa fine-tuningom poslednjeg konvolucionog bloka. Najbolji rezultat dao je fine-tune model: test accuracy 56,91% i macro F1 0,570. To je u skladu sa rezultatima iz literature za isti zadatak. Custom modeli su ostali znatno ispod toga (VGG-lite 35,14%, hibrid 27,72%), što pokazuje koliko pomaže prethodno učenje na ImageNet-u.

Ključne reči: CNN, transfer learning, fine-tuning, klasifikacija slika, umetnički pokreti, Pandora 18K

Sadržaj

1	Uvod	2
2	Srodni radovi	2
3	Skup podataka	2
3.1	Pandora 18K: poreklo i struktura	2
3.2	EDA: šta smo primetili na skupu	3
3.3	Podela na trening, validaciju i test	5
4	Metode	6
4.1	Custom CNN modeli	6
4.1.1	VGG-lite	6
4.1.2	Hibrid (Inception-stil)	6
4.2	Transfer learning sa dense glavom	6
4.3	Fine-tuning poslednjeg bloka	6
4.4	Evaluacija	6
5	Rezultati	7
5.1	Uporedna tabela	7
5.2	Custom modeli	7
5.3	Transfer modeli	7

5.4	Analiza grešaka po klasama	10
6	Diskusija	12
7	Zaključak	12

1 Uvod

Kad gledamo sliku u galeriji, lako uočimo da li je reč o impresionizmu, kubizmu ili pop artu, ali je teško objasniti koji od pravaca je u pitanju ako se ne zna tačan autor slike. Model ne traži objekat na slici, već način slikanja: potez, boju, kompoziciju, stepen apstrakcije. Zato je prepoznavanje umetničkog pokreta teži zadatak od klasične klasifikacije, posebno kad su dva pokreta bliska i po vremenu i po izgledu.

Skup Pandora 18K sadrži 18 038 slika u 18 klasa, od vizantijske ikonografije do pop arta. U ovom projektu smo na tom skupu uporedili mreže koje učimo od nule i pristup zasnovan na pretreniranoj InceptionV3 mreži.

Cilj nam je bio da vidimo koliko dobijamo samim treniranjem male CNN arhitekture, koliko pomaže zamena poslednjeg sloja na već naučenoj mreži, i da li ima smisla pustiti da se prilagodi još jedan konvolucioni blok. Sve smo radili na istoj podeli podataka, da bi poređenje bilo pravedno.

2 Srodni radovi

Florea, Toca i Gieske su uveli Pandora 18K i pokazali da se stilovi mogu razlikovati i klasičnim metodama, kombinacijom boje i topografskih deskriptora sa boosting-om. To je dobar polazni kontekst, ali duboke mreže na većem broju klasa daju drugačije rezultate.

Yu, Jin i Hsu su na istom skupu testirali VGG-lite, hibridnu arhitekturu i transfer learning sa InceptionV3. Njihov VGG-lite je imao oko 31% tačnosti, hibrid oko 36%, a transfer sa fine-tuningom oko 56 do 57%. Mi smo se držali slične postavke eksperimenata da bismo mogli da uporedimo brojeve.

Transfer learning je standardan kad ima malo podataka u novom domenu. Zamrzne se veći deo mreže naučene na ImageNet-u, doda nova glava za naše klase, pa se eventualno odmrzne poslednji deo mreže malim learning rate-om. Za InceptionV3 ulaz je obično 299×299 piksela, sa predprocesiranjem koje očekuje opseg vrednosti od -1 do 1 .

3 Skup podataka

3.1 Pandora 18K: poreklo i struktura

Pandora 18K je javno dostupan skup slika umetničkih dela koji su uveli Florea, Toca i Gieske. Slike su prikupljene sa interneta i organizovane po umetničkom pokretu, zatim po autoru. Tipična putanja izgleda ovako:

```
Pandora_18k/09_Impressionism/Claude Monet/impression-sunrise.jpg
Pandora_18k/18_PopArt/Andy Warhol/campbell-soup.jpg
```

Autori skupa traže da se dataset citira u radovima koji ga koriste. Slike su namenjene za istraživanje i mašinsko učenje, a ne za komercijalnu upotrebu van akademskog konteksta.

U projektu koristimo 18 klasa, hronološki od vizantijske ikonografije do pop arta:

Tabela 1: Broj slika po klasi u skupu Pandora 18K

Br.	Klasa	Broj slika
01	Vizantijska ikonografija	847
02	Rana renesansa	751
03	Severna renesansa	821
04	Visoka renesansa	832
05	Barok	990
06	Rokoko	832
07	Romantizam	895
08	Realizam	1 199
09	Impresionizam	1 257
10	Postimpresionizam	1 276
11	Ekspresionizam	1 027
12	Simbolizam	1 057
13	Fovizam	719
14	Kubizam	1 227
15	Surrealizam	1 072
16	Apstraktna umetnost	1 063
17	Naivna umetnost	1 053
18	Pop art	1 120
Ukupno		18 038


Najveća klasa je postimpresionizam (1 276), najmanja fovizam (719). Odnos je oko 1,8 prema 1. Skup nije savršeno balansiran, ali nije ni ekstremno neravnomeran.

3.2 EDA: šta smo приметili na skupu


Pre treniranja smo pregledali podatke u `notebooks/01_eda.ipynb`.

Broj slika po klasi. Realizam, impresionizam, postimpresionizam i kubizam imaju više od 1 200 primera. Manje zastupljeni su fovizam, rana renesansa i vizantijska ikonografija.


Dimenzije slika. Širina i visina jako variraju. Ima malih skenova i velikih reprodukcija (preko 3 000 piksela). Zato sve slike skaliramo na fiksnu veličinu (224×224 za custom modele, 299×299 za InceptionV3).



Slika 1: Broj slika po klasi




Slika 2: Rasip dijagram širine i visine slika



Slika 3: Histogrami dimenzija slika

Vizuelni uzorci. Na mreži od po jedne slike po klasi odmah se vidi razlika između, recimo, vizantijske ikonografije i pop arta. Ali i srodni pokreti deluju slično: impresionizam i postimpresionizam dele svetlu paletu i labav potez.



Slika 4: Uzorak po jednoj slici iz svake klase

Struktura foldera. Pošto su slike grupisane po autoru unutar pokreta, isti stil se ponavlja na mnogo slika istog slikara. Model može da nauči i specifičnosti autora, ne samo pokreta.

3.3 Podela na trening, validaciju i test

Podela je stratifikovana po klasi ($SEED = 42$). Liste putanja su u `data/splits/train.csv`, `val.csv` i `test.csv`. Test skup nismo koristili tokom podešavanja modela. Na trening skupu smo uključili blagu augmentaciju (horizontalno preslikavanje, rotacija do 10° , zoom do 10%). Za 18 klasa nasumično pogađanje daje 5,56% tačnosti.

Tabela 2: Stratifikovana podela skupa Pandora 18K

Skup	Broj slika	Udeo
Trening	12 626	70%
Validacija	2 706	15%
Test	2 706	15%
Ukupno	18 038	100%

4 Metode

4.1 Custom CNN modeli

4.1.1 VGG-lite

Počeli smo od jednostavne VGG-inspirisane mreže sa četiri bloka (Conv3×3 + MaxPooling), filterima 32/64/128/256, GlobalAveragePooling, Dense(256), Dropout 0,5 i softmax izlazom. Ulaz: 224×224 , Adam lr 0,001, 20 epoha, batch 64. Model ima 1 242 674 parametara.

4.1.2 Hibrid (Inception-stil)

Tanji stem (8/16/32/64) i jedna Inception-stil grana sa paralelnim putanjama 1×1 , 3×3 i 5×5 . Isti ulaz i 20 epoha; hibrid treniran sa batch 128. Model ima 57 434 parametra.

4.2 Transfer learning sa dense glavom

InceptionV3 sa ImageNet težinama, zamrznuta baza, nova glava (GAP + Dropout + Dense). Ulaz 299×299 . Feature keš u `experiments/transfer_dense/features/`. 100 epoha, batch 64; trenabilno 36 882 od 21 839 666 parametara.

4.3 Fine-tuning poslednjeg bloka

Odmrznut poslednji Inception blok (`mixed9`), lr 10^{-5} , do 30 epoha (early stopping na 28). Trenabilno 6 107 154 parametara.

4.4 Evaluacija

Sve modele evaluirali smo skriptom `src/evaluate.py` na test skupu od 2 706 slika. Čuvamo model sa najboljom validacionom tačnošću (`ModelCheckpoint` po `val_accuracy`).

5 Rezultati

5.1 Usporedna tabela


Tabela 3: Usporedni rezultati svih modela

Model	Parametara	Trenabilnih	Ulaz	Epoha	Val acc	Test acc	Macro F1
VGG-lite	1 242 674	1 242 674	224 ²	20	33,85%	35,14%	0,330
Hibrid	57 434	57 434	224 ²	20	28,09%	27,72%	0,238
Transfer dense	21 839 666	36 882	299 ²	100	52,77%	49,93%	0,497
Transfer fine-tune	21 839 666	6 107 154	299 ²	28	59,57%	56,91%	0,570

Napomena: 59,57% je validaciona tačnost fine-tune modela; glavni rezultat je test accuracy 56,91%.

5.2 Custom modeli


VGG-lite je dostigao 35,14% na testu. Hibrid je imao 27,72%, iako ima daleko manje parametara.



Slika 5: Krive učenja — VGG-lite

5.3 Transfer modeli


Dense glava daje 49,93% test accuracy; fine-tuning podiže na 56,91% (+6,98 p.p.). Macro F1 raste sa 0,497 na 0,570.




Slika 6: Krive učenja — hibrid

Tabela 4: Poređenje transfer dense i fine-tune modela


Metrika	Transfer dense	Transfer fine-tune
Test accuracy	49,93%	56,91%
Test loss	1,4698	1,3791
Macro F1	0,4965	0,5704
Weighted F1	0,4912	0,5657



Slika 7: Krive učenja — transfer dense



Slika 8: Krive učenja — transfer fine-tune



Slika 9: Matrica konfuzije — transfer fine-tune

5.4 Analiza grešaka po klasama

Analizu smo radili na najboljem modelu (transfer fine-tune). Na test skupu od 2 706 slika model je uredno klasifikovao 56,91% slika.

Tabela 5: Klase koje model najbolje prepoznaje

Klasa	Recall	Komentar
Vizantijska ikonografija	93,7%	Zlatna pozadina, jasan stil
Pop art	81,5%	Jarke boje, lako se razlikuje
Rana renesansa	74,1%	Prepoznatljiva kompozicija
Kubizam	67,4%	Geometrijski oblici

Tabela 6: Klase koje model najčešće pogrešno klasifikuje


Klasa	Recall	Precision	Problem
Ekspresionizam	27,3%	0,38	Meša se sa postimpresionizmom
Postimpresionizam	40,1%	0,40	Često ide u impresionizam
Romantizam	41,8%	0,40	Meša se sa barokom
Barok	49,3%	0,46	Zbunjuje ga sa rokokoom
Realizam	45,0%	0,47	Često kao impresionizam

Tabela 7: Najčešće zabune između parova klasa


Tačna klasa	Pogrešno predviđeno kao	Broj slika
Fovizam	Postimpresionizam	29
Postimpresionizam	Impresionizam	28
Barok	Rokoko	28
Realizam	Impresionizam	27
Romantizam	Barok	26
Impresionizam	Postimpresionizam	24
Rokoko	Barok	24
Realizam	Romantizam	21
Naivna umetnost	Surrealizam	20
Ekspresionizam	Postimpresionizam	18
Kubizam	Apstraktna umetnost	18

Većina grešaka nije nasumična, već je koncentrisana oko istorijski i vizuelno srodnih pokreta.


1. **Postimpresionizam predviđen kao impresionizam** — slična svetla paleta i potez.
2. **Realizam predviđen kao impresionizam** — meki prelazi i difuzno svetlo.
3. **Romantizam predviđen kao barok** — dramatično svetlo i kontrasti.
4. **Ekspresionizam predviđen kao postimpresionizam** — subjektivni izraz forme.
5. **Fovizam predviđen kao postimpresionizam** — jarke boje; manje primera u skupu.



Slika 10: Recall po klasi — transfer fine-tune



Slika 11: Poređenje recall-a: dense vs fine-tune



Slika 12: Primeri pogrešnih predikcija — transfer fine-tune

Fine-tuning je podigao recall na teškim klasama (npr. surrelizam sa 36,6% na 59,6%). Kod impresionizma recall pada, ali precision raste — macro F1 je pouzdaniji pokazatelj od čistog recall-a.

6 Diskusija

Pretrenirana mreža daje mnogo bolje feature-e za ovaj zadatak nego učenje od nule na oko 12 600 trening slika. Hibridni model nije opravdao očekivanja zbog malog kapaciteta i istog broja epoha kao VGG-lite. Fine-tuning poslednjeg bloka ima smisla jer ImageNet feature-i opisuju objekte i scene, a ne slikarski postupak.

7 Zaključak

Najbolji rezultat dao je InceptionV3 sa fine-tuningom: 56,91% test accuracy i macro F1 0,570. Transfer sa samo novom glavom ima 49,93%. Custom VGG-lite stiže do 35,14%, hibrid do 27,72%. Rezultat fine-tune modela uporediv je sa literaturom za isti skup.

Literatura

- [1] C. Florea, C. Toca, F. Gieske. *Artistic Movement Recognition by Boosted Fusion of Color Structure and Topographic Description*. IEEE WACV, Santa Rosa, CA, USA,

2017.

- [2] Y. Yu, O. Jin, D. Hsu. *Artistic Movement Recognition using Deep CNNs*. Stanford University, CS231n, 2017. <https://cs231n.stanford.edu/reports/2017/pdfs/411.pdf>
- [3] TensorFlow / Keras dokumentacija: InceptionV3, ImageDataGenerator, transfer learning i fine-tuning.